

AI를 활용한 코딩 어시스턴트



최소한의 비용으로 "쓸만한"
AI도구를 "빠르게" 만들 수 있다.



목차

01 요즘 개발자들이 사용하는 툴

02 만들었던 서비스들

03 잠깐의 개념설명

04 활용방안 -open WEBUI

05 활용방안 - Continue

06 구축방안


07 질문





요즘 개발자들이 사용하는 툴



VSCODE 기반 코드에디터 CURSOR




CURSOR



대화형 웹 AI 사이트들

 Gemini

 ChatGPT

 Claude

 perplexity

이거보다
훨씬 많아!



CHAT GPT

OpenAI



로그인

무엇을 도와드릴까요?

Rédigez une note de remerciement
Recommend an easy potluck dish



ChatGPT로 검색하기

ChatGPT와 대화하기

리서치

Sora




더 보기



뭐가달라?

웹사이트, 모델이름

터미널



비용도, 성능도
외부 서비스 구독해서 쓰면 제일 좋다
하지만 외부망이 안되니까...





Get up and running with large language models.

Run DeepSeek-R1, Qwen 3, Llama 3.3, Qwen 2.5-VL, Gemma 3, and other models, locally.

Download ↓

Available for macOS,
Linux, and Windows

전부
무료야!



gemma3

The current, most capable model that runs on a single GPU.

vision 1b 4b 12b 27b

↓ 9.6M Pulls 🏷 21 Tags ⌚ Updated 3 months ago

qwen3

Qwen3 is the latest generation of large language models in Qwen series, offering a comprehensive suite of dense and mixture-of-experts (MoE) models.

tools thinking 0.6b 1.7b 4b 8b 14b 30b 32b 235b

↓ 3.9M Pulls 🏷 35 Tags ⌚ Updated 1 month ago

qwen2.5vl

Flagship vision-language model of Qwen and also a significant leap from the previous Qwen2-VL.

vision 3b 7b 32b 72b


↓ 407K Pulls 🏷 17 Tags ⌚ Updated 2 months ago

llama3.1

Llama 3.1 is a new state-of-the-art model from Meta available in 8B, 70B and 405B parameter sizes.

tools 8b 70b 405b

↓ 98.5M Pulls 🏷 93 Tags ⌚ Updated 7 months ago



애 튜닝



 **Hugging Face**

Models

Datasets

Spaces

Community

Docs

Pricing

Log In

Sign Up

NEW

Get started with Inference in seconds



The AI community building the future.

The platform where the machine learning community collaborates on models, datasets, and applications.

Explore AI Apps

or

Browse 1M+ models

Tasks

Libraries

Datasets

Languages

Licenses

Other

Multimodal

Text-to-ImageImage-to-TextText-to-VideoVisual Question AnsweringDocument Question AnsweringGraph Machine Learning

Computer Vision

Depth EstimationImage ClassificationObject DetectionImage SegmentationImage-to-ImageUnconditional Image GenerationVideo ClassificationZero-Shot Image Classification

Natural Language Processing

Text ClassificationToken ClassificationTable Question AnsweringQuestion AnsweringZero-Shot ClassificationTranslationSummarizationConversationalText GenerationText2Text GenerationSentence Similarity

Audio

Text-to-SpeechAutomatic Speech RecognitionAudio-to-AudioAudio ClassificationVoice Activity Detection

Tabular

Tabular ClassificationTabular Regression

Reinforcement Learning

Robotics

Models 469,541

Filter by name

meta-llama/Llama-2-70b

Text Generation • Updated 4 days ago • 25.2k • 64

stabilityai/stable-diffusion-xl-base-0.9

Updated 6 days ago • 2.01k • 393

openchat/openchat

Text Generation • Updated 2 days ago • 1.3k • 136

l1lyasviel/ControlNet-v1-1

Updated Apr 26 • 1.87k

cerspense/zeroscope_v2_XL

Updated 3 days ago • 2.66k • 334

meta-llama/Llama-2-13b

Text Generation • Updated 4 days ago • 328 • 64

tiiuae/falcon-40b-instruct

Text Generation • Updated 27 days ago • 288k • 899

WizardLM/WizardCoder-15B-V1.0

Text Generation • Updated 3 days ago • 12.5k • 332

CompVis/stable-diffusion-v1-4

Text-to-Image • Updated about 17 hours ago • 448k • 5.72k

stabilityai/stable-diffusion-2-1

Text-to-Image • Updated about 17 hours ago • 782k • 2.81k

Salesforce/xgen-7b-8k-inst

Text Generation • Updated 4 days ago • 6.18k • 57

인터넷이
없어도됨!



```
jiwonkim — ollama run llama3.1:8b — 80x24

Use "ollama [command] --help" for more information about a command.
[jiwonkim@jiwonui-MacBookPro ~ % ollama list]
NAME                                ID                                SIZE      MODIFIED
qwen3:8b                            500a1f067a9f                    5.2 GB    5 weeks ago
nomic-embed-text:latest             0a109f422b47                    274 MB    5 weeks ago
qwen2.5-coder:1.5b-base             02e0f2817a89                    986 MB    5 weeks ago
llama3.1:8b                         46e0c10c039e                    4.9 GB    5 weeks ago
gemma3:27b                          a418f5838eaf                    17 GB     2 months ago
deepseek-r1:14b                    ea35dfe18182                    9.0 GB    5 months ago
llama3.1:latest                     46e0c10c039e                    4.9 GB    5 months ago
eeve_gguf:latest                   d943e03df081                    8.5 GB    13 months ago
llama3:latest                       365c0bd3c000                    4.7 GB    13 months ago
llama3:8b                          365c0bd3c000                    4.7 GB    13 months ago
[jiwonkim@jiwonui-MacBookPro ~ % ollama run llama3.1:8b]
[>>> 야 반갑다 너 신한은행 알아?]
네! 신한은행은 한국의 대형 민간 은행 중 하나입니다.

[>>> 대단한 걸?]
신한은행은 한국에서 가장 오래된 은행 중 하나로, 1926년 설립되었습니다. 현재
는 한국의 금융 시장에서 유명하고 큰 은행으로 성장했습니다. 다양한 금융 서비스
를 제공하며 고객에게 편리함과 신뢰성을 제공하는 것을 목표로 하고 있습니다.

>>> [ ] end a message (/? for help)
```

AI.Lounge

신한금융그룹을 위한 AI Portal 서비스

소속

사번

비밀번호

☐ 비밀번호 기억하기

로그인

4가지 서비스
중 하나!



그룹사 시라운지

AI.Lounge

지식특 | 개발특 | FAQ

마이페이지 | 로그아웃

지식특

+ 채팅방추가

안내문구

ChatGPT

LLaMA



그룹사 시라운지

Al.Lounge

지식톡 | 개발톡 | 관리자메뉴 | FAQ

마이페이지 로그아웃

지식톡

채팅방추가

사용량조회

API관리

API사용신청

로그조회(내부감사)

이상치 탐지

사용자 관리

상세 설정

안내문구

다양한
관리기능





FAQ&마이페
이지

FAQ

마이페이지

마이페이지 0

2023-09-25



2023-10-25



조회

기준일:

건

총 이용건수



원

과금



기간별 과금현황

1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0

사용량
측정까지!



+ New Chat

⊗ Chat 9

⊗ Chat 8

⊗ Chat 7

⊗ Chat 6

⊗ Chat 5

⊗ Chat 4

⊗ Chat 3

⊗ Chat 2

⊗ Chat 1



무엇이든 물어봐 주세요. 질문이 자세할수록 좋은 결과를 기대할 수 있어요!

안녕



안녕하세요! 무엇을 도와드릴까요?

파이썬으로 dfs코드 만들어줘



물론이죠! 다음은 파이썬으로 구현된 깊이 우선 탐색(DFS) 알고리즘 코드입니다.

```
def dfs(graph, start, visited=None):  
    if visited is None:  
        visited = set()  
    visited.add(start)  
    print(start)  
  
    for neighbor in graph[start]:  
        if neighbor not in visited:  
            dfs(graph, neighbor, visited)  
  
# 그래프 예시  
graph = {  
    'A': ['B', 'C'],  
    'B': ['A', 'D', 'E'],  
    'C': ['A', 'F', 'G'],  
    'D': ['B'],  
    'E': ['B'],  
    'F': ['C'],  
    'G': ['C']  
}  
  
dfs(graph, 'A')
```


궁금한 점을 자유롭게 질문해주세요!



터미널은
코드복사가
어려워서
만들었어



아주 간단한 구조



만들어 봤어요

부동산AI 챗봇

부동산 도우미 AI 부물입니다.



[Redacted]

봇입니다.

- 24년 12월 공덕 대장 아파트 실거래가 알려주세요.
- 전세자금 대출의 대출금 사용 용도는 제한이 있나요?
- 고정 금리와 변동 금리의 차이점은 무엇인가요?

질문을 입력해주세요

전송

부동산AI 챗봇

부동산 도우미 AI 부물입니다.



질문자

신한은행 전세 대출 금리 알려주세요



[Redacted]

신한은행의 전세 대출 금리에 대해 안내해 드리겠습니다.

2025년 4월 28일부터 5월 4일까지 적용되는 신한은행의 전세 대출 금리는 다음과 같습니다:

- 금리: 3.78% 이 금리는 특정 조건에 따라 적용되는 것으로 보입니다. 정확한 대출 조건과 개인의 신용 상태에 따라 실제 적용되는 금리는 다를 수 있습니다. 더 자세한 정보나 개인별 맞춤 금리를 확인하시려면 신한은행 고객센터(1599-8000)로 문의하시는 것이 좋습니다.

질문을 입력해주세요

전송

-튜닝

-RAG

-프롬프팅

-모델 클라우드배포

-백엔드 클라우드배포

-프론트 클라우드배포

그냥
해봤어!



잠깐의 개념설명

1.프롬프트
→ 자기암시

2.파인튜닝
→ 최적화


3.RAG
→ 검색(오픈북)

4.모델성능, 크기
→ 아이큐




모델이
좋으면
장땡이야!

모델만 좋음



4가지전부 들어감



쓸만하려면

좋은모델 + RAG + 프롬프트



딱히 튜닝은
필요없어!

 신한은행

개발톡

 [LOGOUT](#)

 New Chat

 Chat 9

 Chat 8

 Chat 7

 Chat 6

 Chat 5

 Chat 4

 Chat 3

 Chat 2

 Chat 1



무엇이든 물어봐 주세요. 질문이 자세할수록 좋은 결과를 기대할 수 있어요!

안녕



안녕하세요! 무엇을 도와드릴까요?

파이썬으로 dfs코드 만들어줘



물론이죠! 다음은 파이썬으로 구현된 깊이 우선 탐색(DFS) 알고리즘 코드입니다.

```
def dfs(graph, start, visited=None):
    if visited is None:
        visited = set()
    visited.add(start)
    print(start)


    for neighbor in graph[start]:
        if neighbor not in visited:
            dfs(graph, neighbor, visited)

# 그래프 예시
graph = {
    'A': ['B', 'C'],
    'B': ['A', 'D', 'E'],
    'C': ['A', 'F', 'G'],
    'D': ['B'],
    'E': ['B'],
    'F': ['C'],
    'G': ['C']
}
```


dfs(graph, 'A')

궁금한 점을 자유롭게 질문해주세요!


요즘엔 더쉽게 구축가능



LLM Server




Frontend




Open WebUI

가져다가
딸깍! 조립



Backend




VS Code Extension



활용방안 1.openWebUI (Private GPT)

사내용으로 충분!

좋은게
넌려있어



활용방안 2.continue (vscode 익스텐션)

Extension: Continue - open-source AI code assistant



Continue - open-source AI code assistant

Continue  continue.dev | 1,311,371 | ★★★★★ (97)

The leading open-source AI code assistant

Restart Extensions

Disable

Uninstall

Switch to Pre-Release Version

☒ Auto Update

DETAILS

FEATURES



Installation

Identifier	continue.continue
Version	1.0.19
Last Updated	2025-07-17, 05:32:43
Size	411.36MB

Marketplace



활용방안 2.continue (vscode 익스텐션)

CONTINUE

sol.html

```
<!DOCTYPE html>
<html lang="en">
<head>
  <meta charset="UTF-8">
  <meta name="viewport" content="width=device-wi
  <title>Document</title>
</head>
<body>
  <form id="loginForm">
    <input type="text" name="username" placeho
    <input type="password" name="password" pla
    <button type="submit">로그인</button>
  </form>
  <div id="message"></div>

  <!-- sol.js 불러오기 -->
  <script src="sol.js"></script>
</body>
</html>
```

JavaScript

sol.js

```
// 로그인 검증 함수
function validateLogin() {
  const username = document.querySelector("input
  const password = document.querySelector("input
  const messageDiv = document.getElementById("me

  if (username === "admin" && password === "admin
    messageDiv.textContent = "로그인 성공!";
    messageDiv.style.color = "green";
  } else {
    messageDiv.textContent = "로그인 실패!";
    messageDiv.style.color = "red";
  }
}
```

sol.js

```
sol.js > validateLogin
1 // 로그인 검증 함수
2 function validateLogin() {
3   const username = document.querySelector("input[name='username']").value;
4   const password = document.querySelector("input[name='password']").value;
5   const messageDiv = document.getElementById("message");
6
7   if (username === "admin" && password === "admin") {
8     messageDiv.textContent = "로그인 성공!";
9     messageDiv.style.color = "green";
10  } else {
11    messageDiv.textContent = "로그인 실패!";
12    messageDiv.style.color = "red";
13  }
14
15  // 입력 필드 초기화
16  document.querySelector("input[name='username']").value = "";
17  document.querySelector("input[name='password']").value = "";
18 }
19
20 // 폼 제출 이벤트 리스너
21 document.getElementById("loginForm").addEventListener("submit", function(event) {
22   event.preventDefault();
23   validateLogin();
24 });
25 function validateLogin() {
26   const username = document.querySelector("input[name='username']").value;
27   const password = document.querySelector("input[name='password']").value;
28   const messageDiv = document.getElementById("message");
29
30   if (username === "admin" && password === "admin") {
31     messageDiv.textContent = "로그인 성공!";
32     messageDiv.style.color = "green";
33   } else {
34     messageDiv.textContent = "로그인 실패!";
35     messageDiv.style.color = "red";
36   }
37
38   // 입력 필드 초기화
39   document.querySelector("input[name='username']").value = "";
40   document.querySelector("input[name='password']").value = "";
41 }
42
43 // 폼 제출 이벤트 리스너
44 document.getElementById("loginForm").addEventListener("submit", function(event) {
45   event.preventDefault();
46   validateLogin();
47 }
```

Local Assistant

Ask a follow-up

Chat Qwen3 8B

Ln 11, Col 44 Spaces: 4 UTF-8 LF JavaScript Port : 550




활용방안 2.continue (vscode 익스텐션)




모델

쉽지?




활용방안 2.continue (vscode 익스텐션)



LLM서버 하나로 다용도 활용




외부망이 안된다면 결국에는
좋은 LLM 서버가 필요!!



 Continue



 PrivateGPT



상상해봐!

이런거 있으면 만들 수 있다.

Mac Studio

개요 macOS 제품 사양



갤러리 보기 +



업무일 기준 무료 익일 배송



손쉬운 무료 반품

Mac 구입과 관련해 궁금한 점이 있으신가요?

[Mac 스페셜리스트와 상담하세요 >](#)

Mac Studio 맞춤 구성하기

Apple M3 Ultra 칩(28코어 CPU, 60코어 GPU, 32코어 Neural Engine)

96GB 통합 메모리

1TB SSD 저장 장치

전면: Thunderbolt 5 포트 2개, SDXC 카드 슬롯

후면: Thunderbolt 5 포트 4개, USB-A 포트 2개, HDMI 포트, 10Gb 이더넷 포트, 헤드폰 잭

보상 판매 내용 추가

보상 판매 대상 컴퓨터를 새 Mac 구매 시 사용할 수 있는 크레딧으로 교환해드리거나, 무료로 재활용해드립니다.*

[시작하기 +](#)

칩(프로세서)

[나에게 알맞은 칩은 무엇일까요? +](#)



성능은..

무료와 유료 중간사이쯤?



픽업:

[재고 확인 +](#)



도착:

수 2025/07/02 — 무료 배송

[추가 배송 옵션 확인 +](#)

₩6,590,000


약 ₩599,091의 VAT 포함*

[할부 옵션 제공](#)

계속




흔히들 보여주는 아키텍처 구성도



너무 어려워!



흔히들 보여주는 아키텍처 구성도



이게
뭐야!!




쉬운 구성도

실 사용으로 충분!


Mac Studio



딸깍



딸깍




구성도

맥 서버



백엔드(API서버)




사내 GPT




Open WebUI

IDE 코드어시스턴트



Continue



정확히는 이렇게 구성



백엔드 API서버

 FastAPI



LangChain




모델서버

사내 GPT 프론트서버




Open WebUI

IDE 코드어시스턴트



 Continue



이게
정확해!

최소한의 비용으로 "쓸만한"
AI도구를 "빠르게" 만들 수 있다.




코드 작성 속도 55% 향상

55%

GitHub Copilot 사용 시, 개발자의 작업 완료 속도가 평균 1.5배 이상 빨라졌습니다. 이는 AI가 반복적인 작업을 얼마나 효과적으로 줄여주는지 보여주는 명확한 증거입니다.

Source: GitHub

주요 연구별 생산성 향상률 비교



McKinsey와 GitHub의 연구 모두 AI가 개발자의 생산성을 크게 향상시킨다는 점을 공통적으로 보여줍니다. 특히 복잡한 작업보다 정형화된 작업에서 효율이 극대화됩니다.

모바일개발망 안에서

- 앱 개발에 활용
- 그 외 GPT로도 활용



결제해서 사용한다면?


디지털서비스개발부 김지원프로

- 엔터프라이즈 사용자 1인당 30달러 기준

인원	월간 총비용 (USD)	연간 총비용 (USD)	연간 총비용 (원화, 약)
15명	\$450	\$5,400	748만 원
30명	\$900	\$10,800	1,497만 원

- 엔터프라이즈 사용자 1인당 60달러 기준

인원	월간 총비용 (USD)	연간 총비용 (USD)	연간 총비용 (원화, 약)
15명	\$900	\$10,800	1,497만 원
30명	\$1,800	\$21,600	2,994만 원



끝



감사합니다.